

PORTFOLIO

양 송 이

양 송 이 YANG SONG I

데이터 구조 설계부터 품질 검증까지, 데이터가 올바르게 작동하는 환경을 만드는 양송이입니다



프로필

이름 양 송 이 (YANG SONG I)
생년월일 2002.02.19
기술 블로그 <https://blog.naver.com/songeeeeey>
GitHub <https://github.com/songeeeeey>

학력

2020.03 ~ 2026.02 국민대학교 정보보안암호수학과 졸업
(부전공: 소프트웨어미디어융합전공)
2017.03 ~ 2020.02 청다오청운한국학교 졸업

교육 이수

2025.06 ~ 2025.12 SK 네트워크 Family AI캠프 17기 수료 (6개월)
- 데이터 분석: 데이터 전처리, 머신러닝, 딥러닝
- LLM 개발: 프롬프트 엔지니어링, 파인튜닝, 멀티모달
- 웹 개발: Django, Linux, AWS

자격증

SQLD (SQL 개발자) 2025.06 취득
컴퓨터활용능력 1급 2025.03 취득

기술 역량

Language	Python, SQL
Database	MySQL, FAISS(Vector DB)
Data Analysis	Pandas, Numpy, Matplotlib, Seaborn
Model Training	PyTorch, Scikit-learn
LLM Application	LangChain, LangGraph, OpenAI API, HuggingFace
Backend / Serving	Django, FastAPI
Cloud & DevOps	AWS (EC2, RDS), Docker
Collaboration	Git/GitHub, Notion

Project 1. AI 기반 회의 자동화 시스템 구축

합성 데이터 품질 검증 기반 AI 회의 자동화 플랫폼



개발 기간 2025.10.28 ~ 2025.12.18 (총 52일)

팀 인원 6명 담당 역할 데이터 파트

- 합성 데이터 설계 및 생성
- 합성 데이터 검증 파이프라인 구축
- 프로젝트 기획 및 문서 작성

기술 스택


Language	Python
LLM Model	Qwen3-8B, Whisper
LLM Framework	LangChain
Retrieval	FAISS, HuggingFace dragonkue embedding
Backend	Django, Nginx, FastAPI
Database	MySQL
Frontend	HTML, CSS, JavaScript
Cloud & Deployment	AWS (EC2, RDS), RunPod, Docker




Project 1. AI 기반 회의 자동화 시스템 구축

합성 데이터 품질 검증 기반 AI 회의 자동화 플랫폼

ERD



시스템 아키텍처



Project 1. AI 기반 회의 자동화 시스템 구축

합성 데이터 품질 검증 기반 AI 회의 자동화 플랫폼

트러블슈팅 1. 초기 파인튜닝 학습 효과 미비

(1) 문제 발견

[초기 파인튜닝 데이터셋]
- IT 용어집

```
{
  "messages": [
    {
      "role": "user",
      "content": "디지털 서명이란 무엇인가?"
    },
    {
      "role": "assistant",
      "content": "메시지의 수신자로 하여금 그 메시지의 발신자와 무결성을 증명하고 위조를 방지하도록 하는 암호학적 변환 또는 원래의 메시지에 추가된 데이터를 말한다."
    }
  ]
}
```

(2) 원인 분석

- 1. 용어집 데이터는 단순 정의만 포함 → 맥락 파악 효과 X
- 2. 도메인 확장 불가능
- 3. JSON 출력 형식 불안정

(3) 데이터셋 재구성 전략

[변경된 파인튜닝 합성 데이터셋]

- 전문 대비 JSON 형식의 안건/태스크 합성 데이터셋 few-shot prompt로 생성

system 프롬프트	<pre>{ "messages": [{ "role": "system", "content": "당신은 회의록 전문을 분석하는 AI입니다. 반드시 다음 JSON 스키마로만 출력하세요. (중략) 출력 스키마: { \"agendas\": [\"안건1\", \"안건2\", ...], \"tasks\": [{ \"who\": \"담당자 이름 또는 역할 (없으면 '미정')\", \"what\": \"구체적인 할 일 내용\", \"when\": \"기한 또는 예상 시점 (명확히 언급되지 않으면 '미정', 모호하면 원문 표현 그대로 기록 예: '다음 회의 전', '내일까지')\" }] }</pre>
user 프롬프트	<pre>{ "role": "user", "content": "다음 회의록에서 주요 안건과 누가 언제까지 무엇을 하기로 했는지 JSON 형식으로 추출하세요. (회의록 전문 중략)" }</pre>
assistant 프롬프트	<pre>{ "role": "assistant", "content": "{ \"agendas\": [\"UI 디자인의 현재 진행 상황 및 완료 예정일 확인\", (안건 중략)], \"tasks\": [{ \"who\": \"현주\", \"what\": \"상세 페이지 디자인 완성\", \"when\": \"다음 주 금요일\" }, (태스크 중략)] }"</pre>

→ 데이터셋 전면 재구성 결정

→ 사전 정의된 JSON 출력 구조를 안정적으로 유지

Project 1. AI 기반 회의 자동화 시스템 구축

합성 데이터 품질 검증 기반 AI 회의 자동화 플랫폼

트러블슈팅 1. 초기 파인튜닝 학습 효과 미비

(4) RAG 시스템 도입

- 1단계: Vector DB 구축
 - FAISS 기반 벡터 데이터베이스
 - 도메인별 전문 용어 사전 구축
 - HuggingFace dragonkue로 임베딩
- 2단계: 도메인 선택 UI
 - 사용자가 회의 전 도메인 선택 (IT/마케팅/디자인/회계)
 - 선택한 도메인의 용어 사전 활성화
- 3단계: LangChain Agent 연동
 - Agent가 회의록 생성 중 모르는 용어 감지
 - Vector DB에서 유사도 검색 (Cosine Similarity)
 - 검색된 정의를 LLM 컨텍스트에 추가

(5) 실제 모델 결과

- 안건 추출

agenda_id	1	2
안건	시스템 아키텍처 및 모델 관리	데이터 전처리 및 사용자 인프라 관리
안건 설명	시스템 아키텍처 설계 및 사용된 모델 관리	데이터 전처리 및 사용자 인프라 관리
요약	누가: 박지수, 최동현, 신승철 무엇을: 시스템 아키텍처 설계 및 모델 관리 언제: null 어디서: null 왜: 시스템 운영 및 업그레이드를 위한 아키텍처 및 모델 관리 어떻게: 시스템 아키텍처 설계 및 모델 관리	누가: 박지수, 최동현 무엇을: 데이터 전처리 및 사용자 인프라 관리 언제: null 어디서: null 왜: 시스템 운영을 위한 데이터 전처리 및 인프라 관리 어떻게: 데이터 전처리 및 인프라 관리
안건 요약	박지수, 최동현, 신승철 시스템 아키텍처설계 및 사용된 모델 관리를 담당하며, 시스템 운영 및 업그레이드를 위한 관리를 진행할 예정입니다.	최동현과 박지수가 시스템 운영을 위한 데이터 전처리 및 사용자 인프라 관리를 담당하며, 필요한 데이터를 처리하고 인프라를 관리할 예정입니다.

- 태스크 추출

태스크 내용	담당자	마감	날짜
시스템 아키텍처 작성	박지수 (1팀)	오늘	2025-12-16
유저 인프라 다운 업데이트	박지수 (1팀)	null	null
파인튜닝 모델 보여주기	최동현 (1팀)	null	null

Project 1. AI 기반 회의 자동화 시스템 구축

합성 데이터 품질 검증 기반 AI 회의 자동화 플랫폼

트러블슈팅 2. 합성 데이터 신뢰성 검증

(1) 의문점

Fine-tuning 학습 데이터로 실제 회의록이 아닌
"합성 데이터(Synthetic Data)"를 사용해도 되는가?



합성 데이터의 품질과 **신뢰성 검증 필요**

(2) 3단계 검증 프로세스

- 형식, 의미, 중복 세 가지 기준으로 검증

① 스키마 정합성 검증

- JSON 파싱 오류 검사
- agendas, tasks 필드 존재
- 필드 타입 규칙 일치 확인



-11개

② 의미 정합성 검증

- 화자-담당자 정합성 검사
- 기한 패턴 정규식 검사
- cosine similarity < 0.5
태스크 비율로 score 차감



-49개

③ 중복 데이터 제거

- MD5 해시 기반 중복 탐지
- 중복 쌍 68개 탐지



-68개

최종 데이터셋

2,493개

Project 1. AI 기반 회의 자동화 시스템 구축

합성 데이터 품질 검증 기반 AI 회의 자동화 플랫폼

Fine-tuning 성능 검증

평가 방법: ① GPTScore (Qwen3-14B 기반 자동 평가) ② LLM as a judge (GPT-4o-mini, 5점 척도)

*GPTScore는 log-likelihood 기반 점수로 0에 가까울수록 우수

[BASE Qwen3-8B] JSON 파싱 실패 | 🕒 249.809초

지표	GPTScore	LLM as a judge
faithfulness	-2.453	1/5
instruction_following	-2.625	1/5
structure_clarity	-2.734	1/5

VS

[Fine Tuned Qwen3-8B] 일관된 JSON 출력 | 🕒 166.94초

지표	GPTScore	LLM as a judge
faithfulness	-0.432	5/5
instruction_following	-0.436	4/5
structure_clarity	-0.453	5/5

- ➡ GPTScore 약 6배 향상
- ➡ LLM as a judge 최대 5/5 달성
- ➡ 처리 속도 33% 단축

Project 2. 도서관 이용자 이탈률 예측

EDA 기반 핵심 변수 도출 및 Stacking Ensemble 이탈 예측 모델 개발

개발 기간 2025.08.12 ~ 2025.08.13 (총 2일)

팀 인원 5명

담당 역할 데이터 파트

- 데이터 수집 및 전처리
- EDA
- 파생변수 설계 담당

기술 스택

Language	Python
Data Analysis	Pandas, Numpy
Visualization	Matplotlib, Seaborn
Machine Learning	Scikit-learn
Collaboration	Git/GitHub, Notion



서울시민 도서관 이용자 이탈 예측

1 개요

2 개인 이탈 예측

3 단체 이탈 예측

4 결과 분석



사용자 개인 특성

성별을 선택해주세요

☒ 남자 ☐ 여자

사는 지역을 선택해주세요

금천구

나이를 입력해주세요

29

직업을 선택해주세요

구직중

학력을 선택해주세요

☐ 초등학교 졸업 이하
☐ 중학교 졸업
☐ 고등학교 졸업
☒ 대학교 졸업

소득을 선택해주세요

100만원 미만

 사용자 도서관 이용 특성

도서관 이용 경험

☐ 1년 안에 이용함

☒ 과거에만 이용함

거주지와 도서관이 인접한가요?(도보 20분 기준)

☐ 인접하다

☒ 아니다

 이탈 가능성 예측

예측하기

이탈 가능성 예측 결과

이탈 확률이 69.58% 로, '이탈 예상' 회원입니다.

이탈 확률: 70%

Project 2. 도서관 이용자 이탈률 예측

EDA 기반 핵심 변수 도출 및 Stacking Ensemble 이탈 예측 모델 개발

데이터 전처리 서울특별시 도서관 이용실태 설문 데이터

1. 이상치 제거

- income 컬럼의 값 99(모름/무응답)를 이상치로 판단하여 제거

2. 타겟 변수 직접 설계 — churn 파생변수 생성

- '미래 도서관 이용 의향 없음' 응답을 이탈(churn = 1)로 직접 정의하고 생성

3. 지역 데이터 군집화

- 서울시 25개 구 → 거주지/소득과 도서관 이용률 상관관계 기반으로 3개 그룹으로 군집화

4. 범주형 변수 재코딩



- education 컬럼: 7개 범주 → 4개로 병합
- experience 컬럼: 평생 미방문(3) 제거 후 이진화 (0/1)
- gender 컬럼: 1/2 → 0/1 이진화
- distance 컬럼: 다중값 → 인접(1)/비인접(0)

대학교 중퇴·전문대·4년제를 의미 단위로 통합

도서관 이용 경험 유무로 단순화

여자(0)/남자(1)로 재정의

자치구 내 도보 이용 기준으로 인접 여부 직접 정의



Project 2. 도서관 이용자 이탈률 예측

EDA 기반 핵심 변수 도출 및 Stacking Ensemble 이탈 예측 모델 개발

모델링 결과

1. 클래스 불균형 처리

- 비이탈 89.4% vs 이탈 10.6%
- SMOTEENN 적용

2. 최종 모델

- RF+LGB+XGB 스택킹 앙상블
- 단일 모델 대비 최고 성능

3. 성능 개선

- 하이퍼파라미터 튜닝 후 테스트 정확도 0.750 → 0.762
- 과적합 해소

한계점

1. 이탈 클래스 정밀도 낮음

- 이탈 클래스 precision 0.30
- 데이터 불균형의 근본적 한계

2. 데이터 선정

- 클래스 불균형까지 고려한 데이터 선정 필요성 체감
- 설문 응답자의 주관적 응답에 의존
- 실제 이용 패턴과 괴리 가능성

프로젝트 요약 카드

Project 1. AI 기반 회의 자동화 시스템 구축

항목	내용
담당 역할	합성 데이터 설계 및 생성, 품질 검증 파이프라인 구축, 프로젝트 기획·문서 작성
핵심 성과	- 합성 텍스트 데이터 2,621건 설계, 생성 → 3단계 검증으로 2,493건 정제 - 파인튜닝 모델 faithfulness 1/5 → 5/5, GPTScore 약 6배 향상 - 처리 속도 33% 단축 및 JSON 파싱 실패 완전 해소
주요 기술 스택	Python, LangChain, MySQL, HuggingFace

Project 2. 도서관 이용자 이탈률 예측

항목	내용
담당 역할	데이터 수집·전처리, EDA 및 파생변수 설계
핵심 성과	- EDA로 이탈 핵심 변수 도출 (experience, 상관관계 -0.38) - 7개 변수 재코딩 및 지역 군집화 등 파생변수 직접 설계 - 최종 모델 테스트 정확도 0.76, 이탈 클래스 재현율 0.73 달성
주요 기술 스택	Python, Pandas, Scikit-learn, Matplotlib, Seaborn

소중한 시간 내어 검토해 주셔서 감사합니다.